

Detecção de Tumores Cerebrais: Uma Abordagem Focada em Mineração de Dados

Julio Rodrigues, Hugo Vieira, Thays Costa

julio.csr.271@aluno.ufsj.edu.br, {hugos193040, vercoza.thays}@gmail.com

25 de Maio de 2024



1 Introdução

2 Metodologia

3 Resultados

4 Considerações Finais

1 Introdução

2 Metodología

3 Resultados

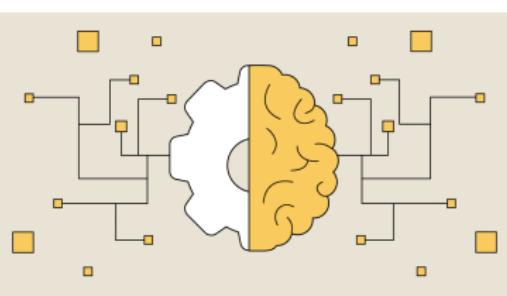
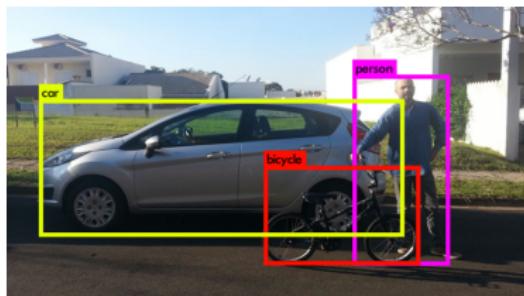
4 Considerações Finais

O Problema

Em linhas gerais...

Detectar a localização de diferentes tipos de tumores cerebrais em diferentes imagens de tomografias.

- Problema de Machine Learning x Visão Computacional;
- Algoritmo de Detecção de Objetos

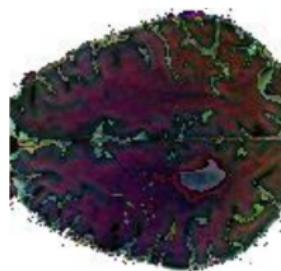


0 Imagens disponíveis em:

<https://datascientest.com/en/machine-learning-what-is-it-and-why-does-it-change-the-world/> e
<https://www.i2ai.org/content/blog/2021/1/conheca-m-o-yolo-v4-o-estado-da-arte-em-visao-computacional/>

Base de Dados

- Extraída do Kaggle¹;
- 9900 imagens de scans cerebrais (RGB);
- Dividida entre treino, validação e teste (70%, 20% e 10%);
- Sem duplicatas e com a mesma resolução (139 x 132);



¹ Disponível em:

<https://www.kaggle.com/datasets/pkdarabi/medical-image-dataset-brain-tumor-detection/data>

1 Introdução

2 Metodologia

- I. Modelo Base
- II. Técnicas de PDI
- III. Machine Learning em Pré-Processamento
- IV. Pré-Processamento e Otimização

3 Resultados

4 Considerações Finais

1 Introdução

2 Metodología

- I. Modelo Base
 - II. Técnicas de PDI
 - III. Machine Learning em Pré-Processamento
 - IV. Pré-Processamento e Otimização

3 Resultados

4 Considerações Finais

Notebook Base

- Kaggle: 8 *notebooks* disponíveis;
 - *Notebook* escolhido: Detecção de tumores com YOLOv8²:
 - ① YOLO - **Y**ou **O**nly **L**ook **O**nce, versão 8;
 - ② Algoritmo de detecção de objetos;
 - ③ Métricas melhores;
 - ④ Única CNN;
 - ⑤ Previsão de classes e caixas delimitadoras.

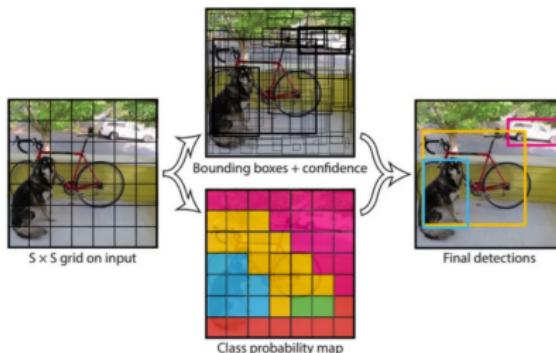
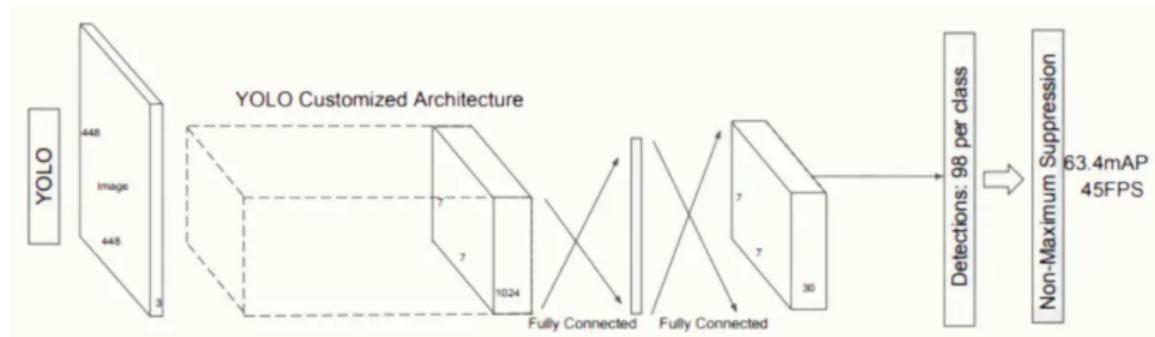


²Disponível em: <https://www.kaggle.com/code/banddaniel/brain-tumor-detection-with-keras-yolo-v8>

Visão Geral do YOLO

- ① A imagem de entrada passa por uma CNN para extrair características da imagem;
- ② As características são passadas através de uma série de camadas totalmente conectadas, que preveem a probabilidades de cada classe e as coordenadas da caixa delimitadora;
- ③ A imagem é dividida em uma grade de células, e cada célula é responsável por prever um conjunto de caixas delimitadoras e probabilidades de classe;
- ④ As caixas delimitadoras são então filtradas usando um algoritmo de pós-processamento para remover caixas sobrepostas e escolher a caixa com a maior probabilidade;
- ⑤ A saída final é um conjunto de caixas delimitadoras previstas e rotuladas para cada objeto na imagem.

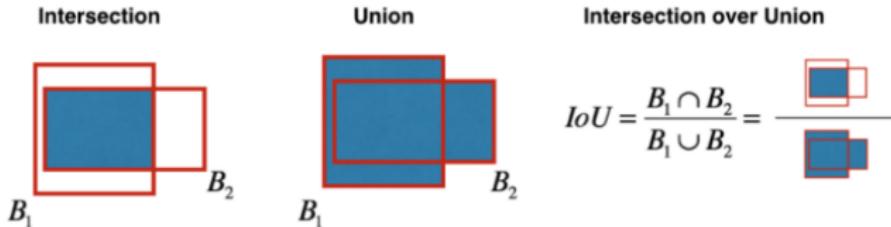
Visão Geral do YOLO



² Imagens disponíveis em: <https://kili-technology.com/data-labeling/machine-learning/yolo-algorithm-real-time-object-detection-from-a-to-z>

Métricas

- Ajuste dos pesos através das funções de custo:
 - ① **Binary Cross-Entropy**: Custo em relação a classificação do objeto;
 - Medir a discrepância entre as probabilidades preditas e as probabilidades reais.
 - ② **IoU**: Custo em relação a detecção do objeto.
 - Medir a sobreposição entre duas caixas delimitadoras;
 - IoU alta → boa sobreposição.



Métricas

- A cada iteração são calculadas as seguintes medidas:

① Box Loss:

- Função de custo da detecção;
 - Erro da sobreposição das caixas delimitadoras.

② Class Loss:

- Função de custo da classificação;
 - Erro da classificação dos dados.

③ Loss:

- Soma das perdas.

Arquitetura

- **Pré-processamento:** Redimensionamento de imagens (640 x 640);
 - **Backbone:** Pesos pré-treinados com o dataset *COCO*;
 - **Otimizador:** AdamW;
 - **Função de custo da classificação:** *Binary Cross-Entropy*;
 - **Função de custo da detecção:** CloU;
 - **Número de épocas:** 120.

Melhorias Propostas

- Uso de Processamento Digital de Imagens (PDI);
 - Otimização;
 - Balanceamento;
 - Melhor avaliação do modelo;
 - Ajuste fino.

1 Introdução

2 Metodologia

I. Modelo Base

II. Técnicas de PDI

III. Machine Learning em Pré-Processamento

IV. Pré-Processamento e Otimização

3 Resultados

4 Considerações Finais

Equalização de Histograma Adaptativa com Contraste Limitado (CLAHE)

- Melhorar o contraste de uma imagem de maneira adaptativa;
 - Melhorar o contraste entre o tumor e as partes do cérebro;
 - Fundamentos:
 - ① Dividir a imagem em blocos;
 - ② Aplicar a equalização de histograma em cada bloco.

Aplicação de CLAHE

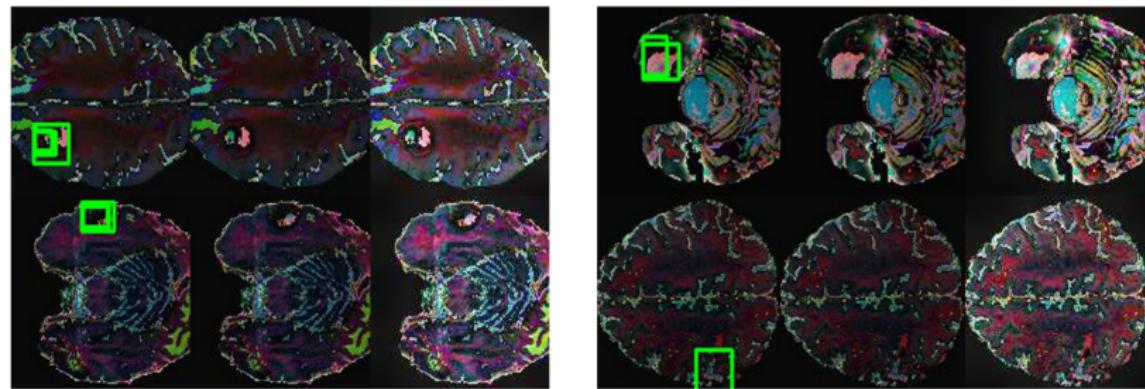


Figura 1: Aplicação de CLAHE em uma amostra da base de dados

Limiarização/binarização de imagens (*thresholding*)

- Separar regiões distintas baseadas na intensidade dos pixels;
 - Delimitar o tumor pela cor característica;
 - Fundamentos:
 - ① Escolha de um valor de limiar;
 - ② Dividir os pixels em duas classes (e.g., preto e branco).

Aplicação de *thresholding*

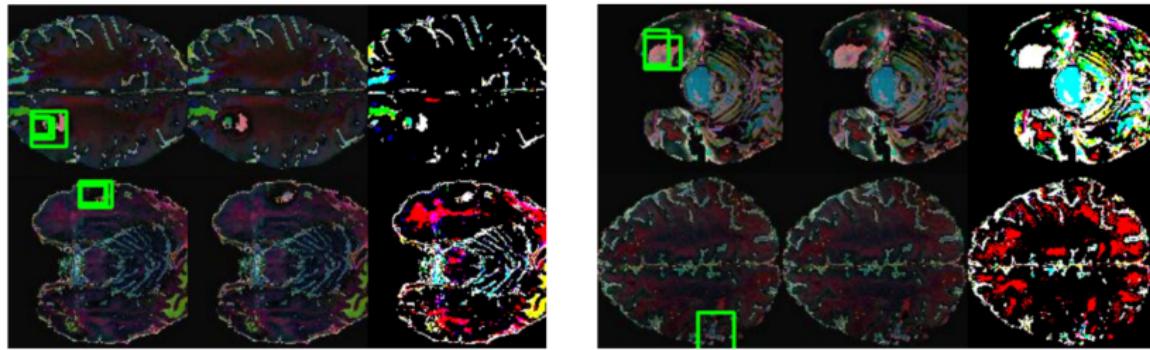


Figura 2: Aplicação de *thresholding* em uma amostra da base de dados

1 Introdução

2 Metodologia

- I. Modelo Base
- II. Técnicas de PDI
- III. Machine Learning em Pré-Processamento**
- IV. Pré-Processamento e Otimização

3 Resultados

4 Considerações Finais

Construção de uma CNN

- Custo computacional alto para manipular o YOLO;
- CNN simples como *sandbox*;
- Teste de múltiplas técnicas em menor tempo;
- Flexibilidade na definição da arquitetura;
- Etapas bem sucedidas poderiam ser aplicadas no YOLO;
- Redução no tempo total de construção do modelo.

1 Introdução

2 Metodologia

- I. Modelo Base
- II. Técnicas de PDI
- III. Machine Learning em Pré-Processamento
- IV. Pré-Processamento e Otimização

3 Resultados

4 Considerações Finais

Pré-Processamento de Imagens

- Normalização de pixels;
 - Camadas de aumento de dados:
 - ① Escala;
 - ② Espelhamento;
 - ③ Contraste;
 - ④ Brilho.
 - Limitações em relação a recursos computacionais.

Otimização

- Redimensionamento de imagens;
 - Utilização de *callbacks*:
 - ① Parada prematura;
 - ② Redução gradual de *learning rate*;
 - ③ Pontos de *backup*.
 - Redução do número de épocas;
 - Aumento do tamanho dos batches.

Balanceamento de Dados

- Poucas imagens sem tumor;
 - 2 ou mais tumores em média;
 - Aplicação de *oversampling* aleatório;
 - Conjunto de treinamento com 14.100 imagens;
 - Redução do conjunto para gerar métricas custosas.

Balanceamento de Dados

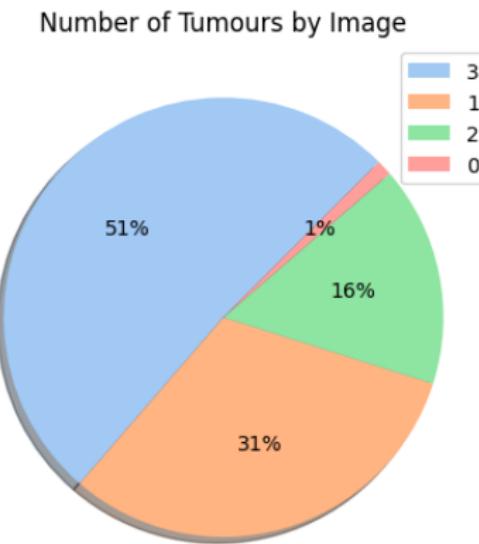


Figura 3: Distribuição do número de tumores por imagem

1 Introdução

2 Metodologia

3 Resultados

- I. Perdas
- II. Novas Métricas
- III. Conjunto de Teste
- IV. Visualização de Detecções

4 Considerações Finais

1 Introdução

② Metodología

3 Resultados

- I. Perdas
 - II. Novas Métricas
 - III. Conjunto de Teste
 - IV. Visualização de Detecções

4 Considerações Finais

Modelo Base

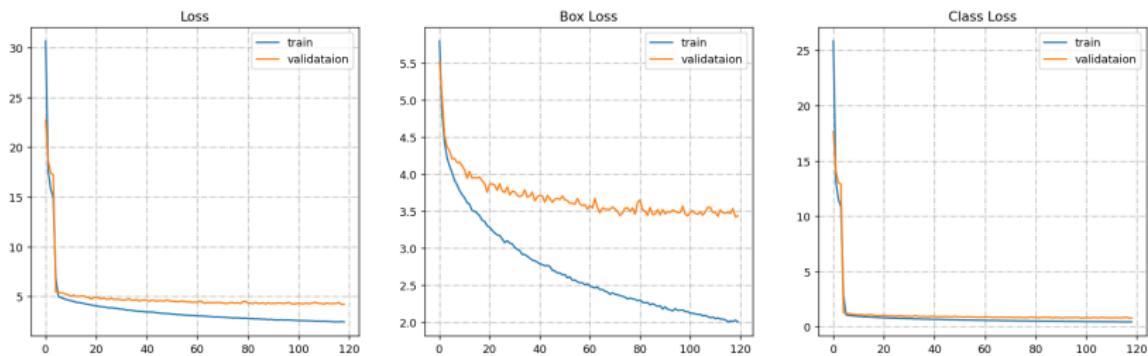


Figura 4: Variação das perdas por época com o modelo base

Modelo Proposto (Base Reduzida)

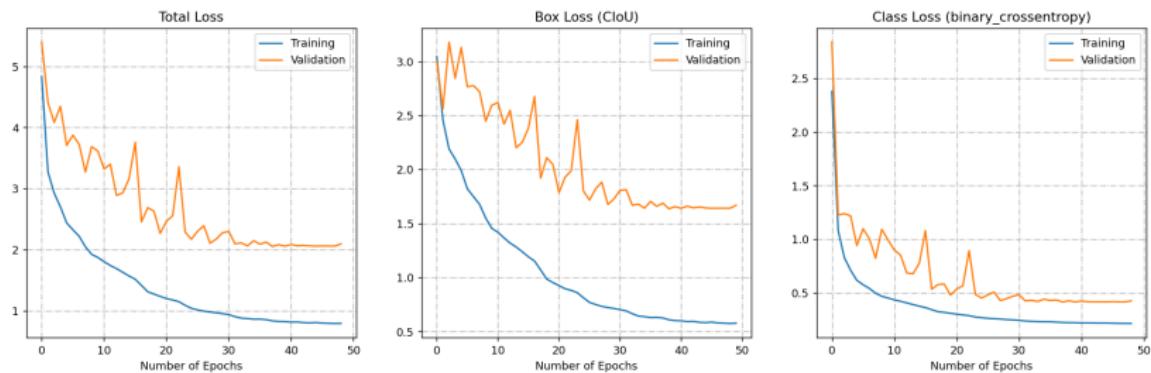


Figura 5: Variação das perdas por época com o modelo reduzido

Modelo Proposto (Base Balanceada)

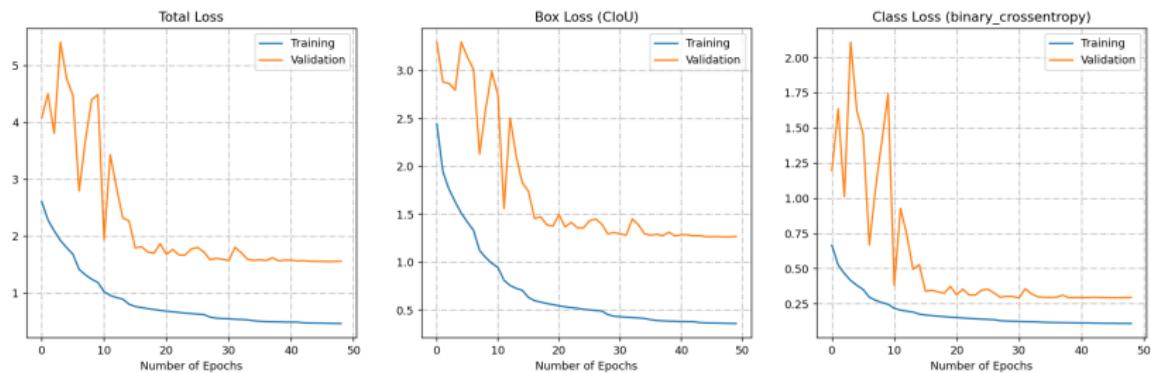


Figura 6: Variação das perdas por época com o modelo balanceado

Comparação Geral

Tabela 1: Perdas entre o modelo original e proposto

Métricas	Original	Reduzido	Balanceado
<i>Loss</i>	4,18	2,05	1,55
<i>Box Loss</i>	3,39	1,64	1,26
<i>Class Loss</i>	0,77	0,42	0,29

1 Introdução

2 Metodologia

3 Resultados

I. Perdas

II. Novas Métricas

III. Conjunto de Teste

IV. Visualização de Detecções

4 Considerações Finais

BoxCOCOMetrics

- **mAP:**
 - ① Precisão Média;
 - ② mAP - IoU: em relação a sobreposição das caixas;
 - ③ mAP - área: em relação à área da caixa.
 - **Recall:**
 - ① Sensibilidade;
 - ② Recall - máx. de deteções: em relação ao número de detecções;
 - ③ Recall - área: em relação à área da caixa.
 - Métricas mensuradas utilizando o conjunto reduzido de dados.

mAP

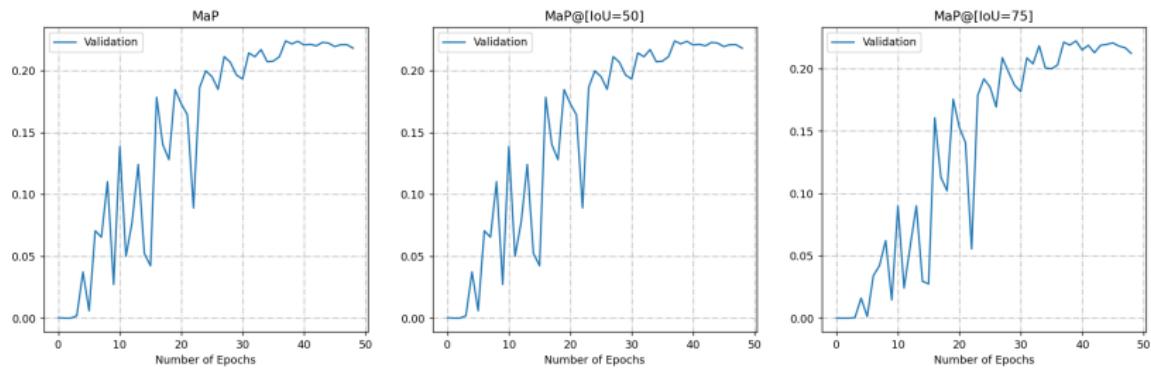


Figura 7: Variação da mAP por época com o modelo reduzido

mAP por Área

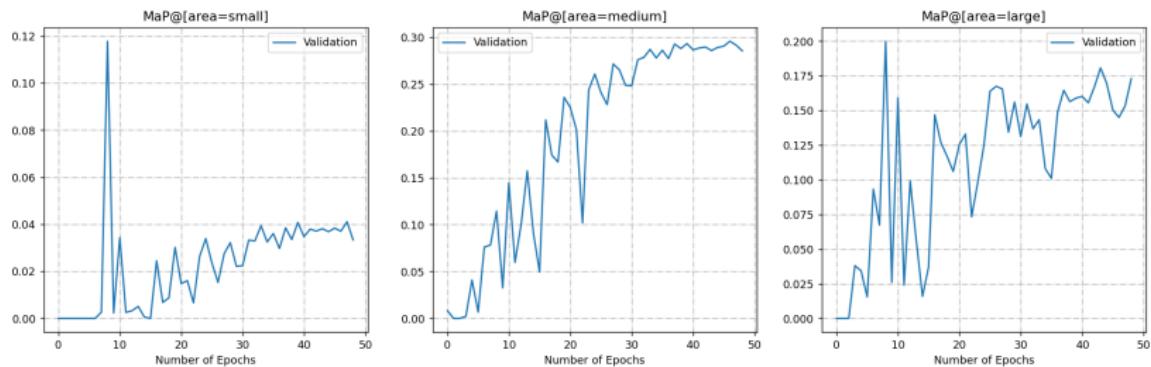


Figura 8: Variação da mAP por área por época com o modelo reduzido

Recall

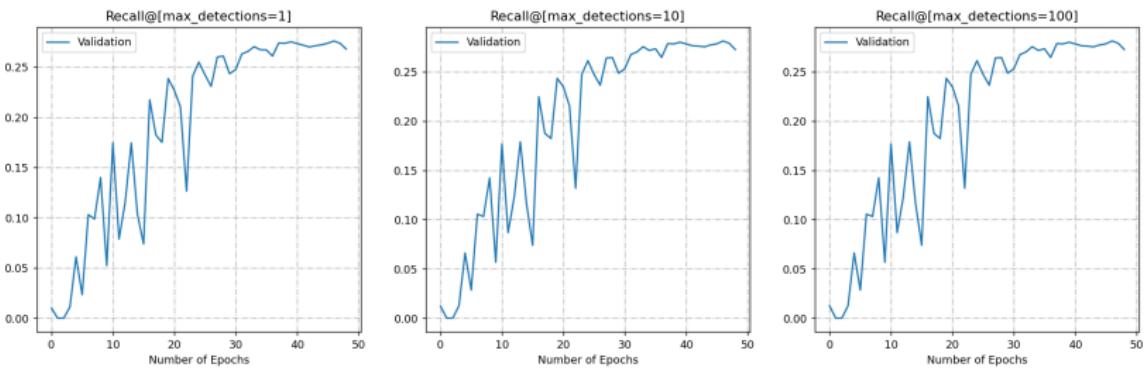


Figura 9: Variação do *Recall* por época com o modelo reduzido

Recall por Área

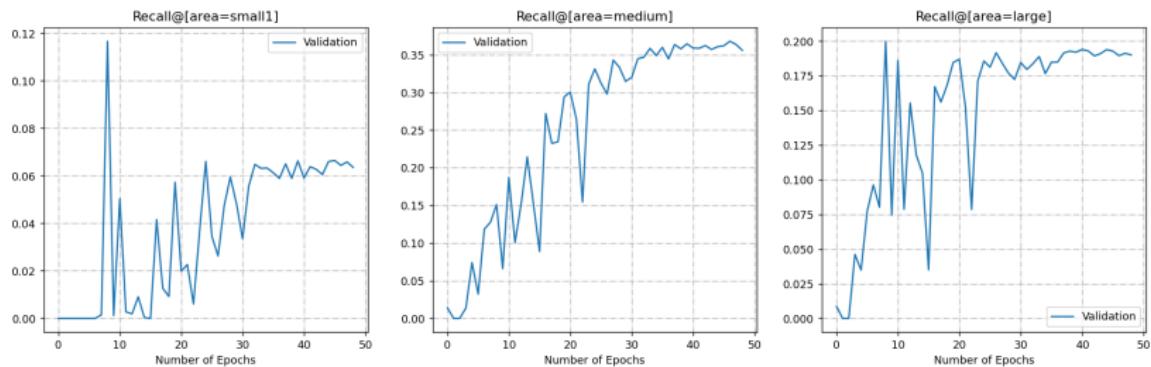


Figura 10: Variação do *Recall* por área por época com o modelo reduzido

1 Introdução

2 Metodologia

3 Resultados

- I. Perdas
- II. Novas Métricas
- III. Conjunto de Teste**
- IV. Visualização de Detecções

4 Considerações Finais

Avaliação com Modelo Base

Tabela 2: mAP base e por área com modelo base

Métrica	Base	IoU=50	IoU=75
mAP	0,048	0,188	0,005
Métrica	area=small	area=medium	area=large
mAP	0,026	0,056	0,0

Tabela 3: Recall em detecções e por área com modelo base

Métrica	max_det=1	max_det=10	max_det=100
Recall	0,089	0,089	0,089
Métrica	area=small	area=medium	area=large
Recall	0,047	0,087	0,0

Avaliação com Modelo Proposto (Base Reduzida)

Tabela 4: mAP base e por área com modelo proposto

Métrica	Base	IoU=50	IoU=75
mAP	0,22	0,42	0,20
Métrica	area=small	area=medium	area=large
mAP	0,04	0,27	0,24

Tabela 5: Recall em detecções e por área com modelo proposto

Métrica	max_det=1	max_det=10	max_det=100
Recall	0,27	0,28	0,28
Métrica	area=small	area=medium	area=large
Recall	0,07	0,35	0,25

Avaliação com Modelo Proposto (Base Balanceada)

Tabela 6: mAP base e por área com modelo proposto

Métrica	Base	IoU=50	IoU=75
mAP	0,34	0,55	0,36
Métrica	area=small	area=medium	area=large
mAP	0,09	0,44	0,49

Tabela 7: Recall em detecções e por área com modelo proposto

Métrica	max_det=1	max_det=10	max_det=100
Recall	0,38	0,38	0,38
Métrica	area=small	area=medium	area=large
Recall	0,14	0,49	0,50

1 Introdução

2 Metodologia

3 Resultados

- I. Perdas
- II. Novas Métricas
- III. Conjunto de Teste
- IV. Visualização de Detecções

4 Considerações Finais

Modelo Base

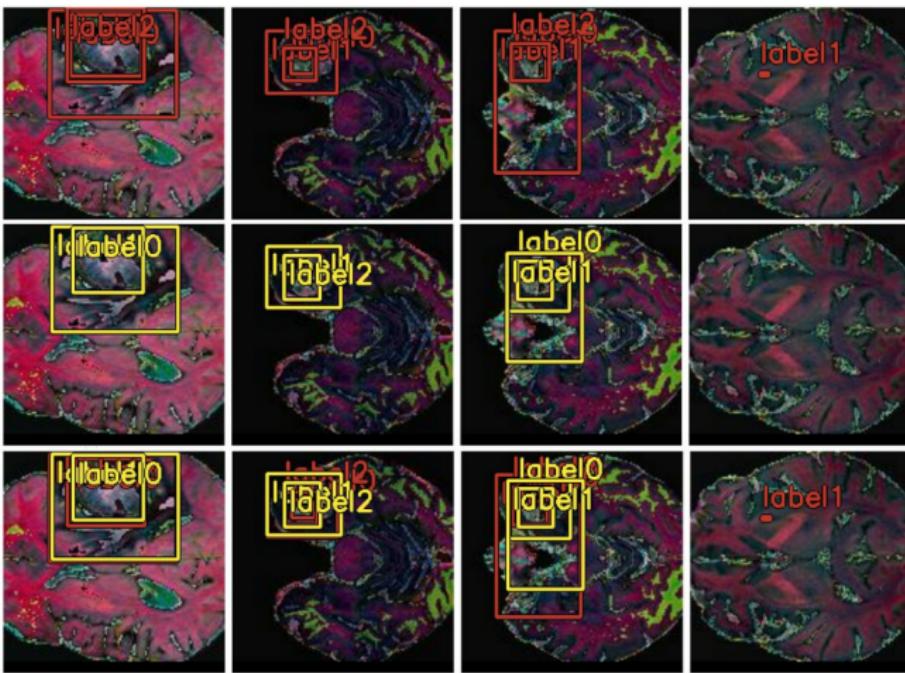


Figura 11: Detecção e classificação de amostras com o modelo base

Modelo Proposto (Base Reduzida)

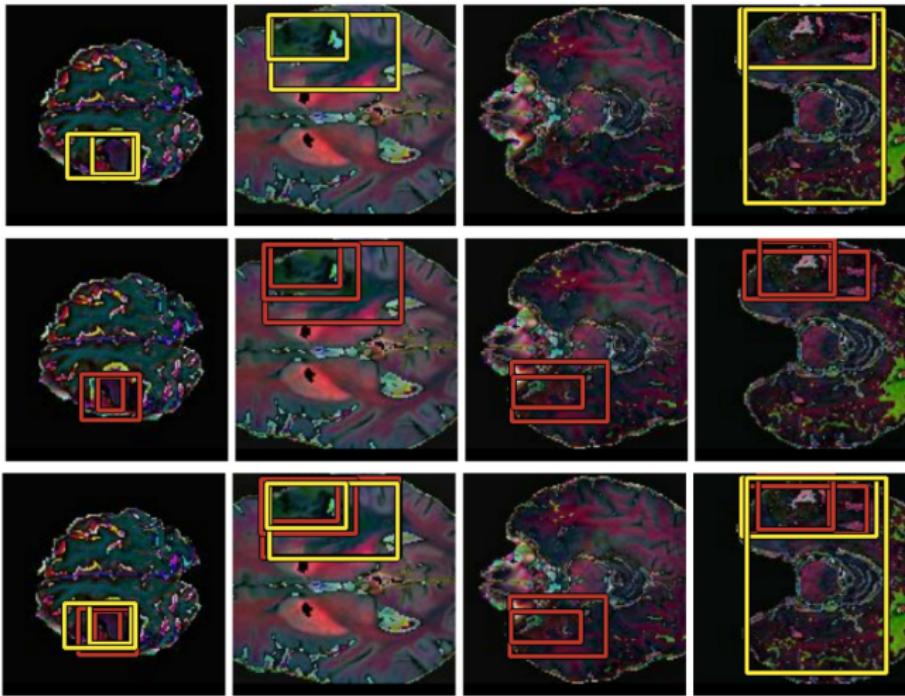


Figura 12: Detecção de amostras com o modelo proposto reduzido

Modelo Proposto (Base Balanceada)

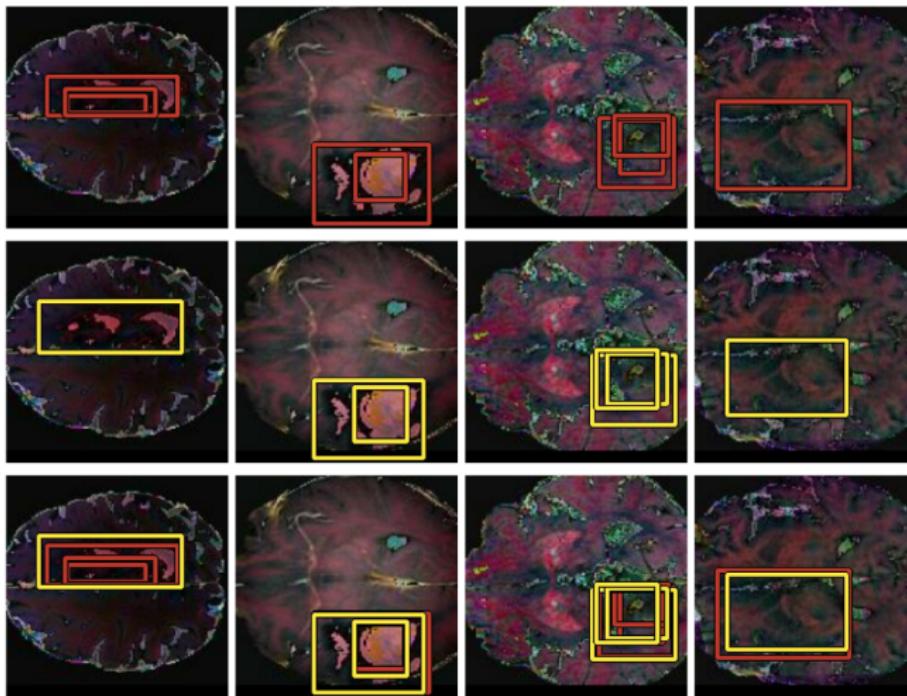


Figura 13: Detecção de amostras com o modelo proposto balanceado

1 Introdução

2 Metodologia

3 Resultados

4 Considerações Finais

Trabalhos Futuros

- Revisitar etapas de pré-processamento;
 - Técnicas avançadas e combinações de PDI;
 - Expansão da base de dados;
 - Validação cruzada;
 - Utilização de outro modelo comparável ao YOLO;
 - Testes estatísticos;
 - Ajuste fino.

Conclusões

- Melhor generalização comparado ao modelo base;
 - CloU quase 3x menor;
 - mAP mais de 7x maior.
 - Longe de estar adequado para uso em produção;
 - Aplicação de técnicas de PDI e mineração de dados;
 - Redução no tempo de execução (+6x menor);
 - Métricas adicionais para avaliação do modelo.

Obrigado!

Referências I

[Alves, 2020] Alves, G. (2020).

Detecção de objetos com yolo – uma abordagem moderna.

https://iaexpert.academy/2020/10/13/deteccao-de-objetos-com-yolo-uma-abordagem-moderna/?doing_wp_cron=1714068532.8220911026000976562500.

Acessado em: 23/04/2024.

[Darabi, 2024] Darabi, P. K. (2024).

Medical image dataset: Brain tumor detection.

<https://www.kaggle.com/datasets/pkdarabi/medical-image-dataset-brain-tumor-detection?resource=download>.

Acessado em: 14/04/2024.

[Jocher et al., 2023] Jocher, G., Munawar, M. R., and Vina, A. (2023).

Performance metrics deep dive.

<https://docs.ultralytics.com/guides/yolo-performance-metrics/#how-to-calculate-metrics-for-yolov8-model>.

Acessado em: 24/04/2024.

Referências II

[Mirkhan, 2024] Mirkhan, A. (2024).

Yolo algorithm: Real-time object detection from a to z.

<https://kili-technology.com/data-labeling/machine-learning/yolo-algorithm-real-time-object-detection-from-a-to-z>.

Acessado em: 20/04/2024.