

Equipe 1 - Detecção de Tumores Cerebrais

Alunos:

Julio Rodrigues

Hugo Santos

Thays Costa

Sumário


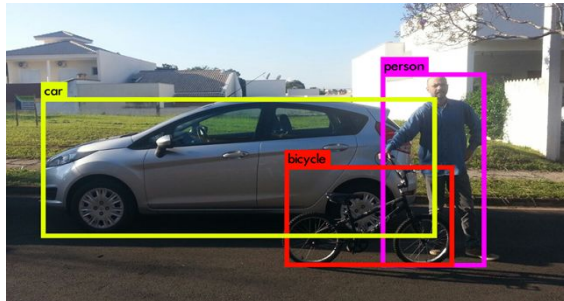
- Introdução
- Base de Dados
- Conceitos
- Metodologia
- Métricas
- Resultados
- Comparação
- Conclusões

Introdução

- Objetivo

Detectar a localização de diferentes tipos de tumores cerebrais em diferentes imagens de tomografias cerebrais

- Problema de Visão Computacional
- Algoritmo de Deteção de Objetos



Disponível em:


<https://www.i2ai.org/content/blog/2021/1/conhecem-o-yolo-v4-o-estado-da-arte-em-visao-compu/>

<https://datascientest.com/en/machine-learning-what-is-it-and-why-does-it-change-the-world>

Base de Dados


- 9900 imagens de *scans* cerebrais;
- Já dividida entre treino, validação e teste (70%, 20% e 10%);
- 3 classes de tumores:
 - Glioma;
 - Meningioma;
 - Metastático.
- Cada imagem possui um arquivo .txt correspondente contendo seu *ground truth* no formato:

`<classe> <coord_x1> <coord_y1> <coord_x2> <coord_y2>`



Base de Dados


Glioma




Meningioma




Metastático



Saudável



Glioma, Meningioma e Metastático

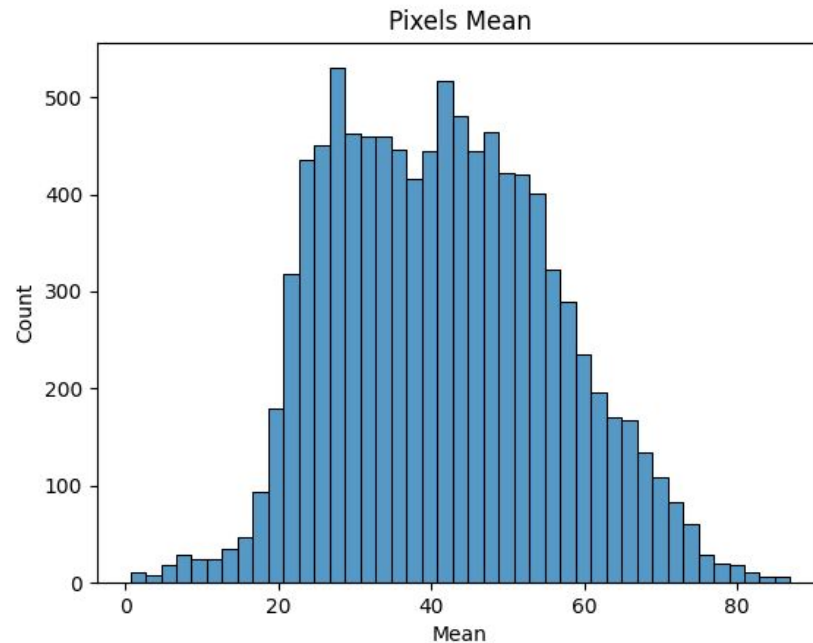


Base de Dados – Informações Básicas

- Todas as imagens possuem a mesma resolução (139 x 132);
- Utilizam o mesmo canal de cores (RGB);
- Não existem duplicatas;
- Desbalanceamento evidente (detecção e classificação).

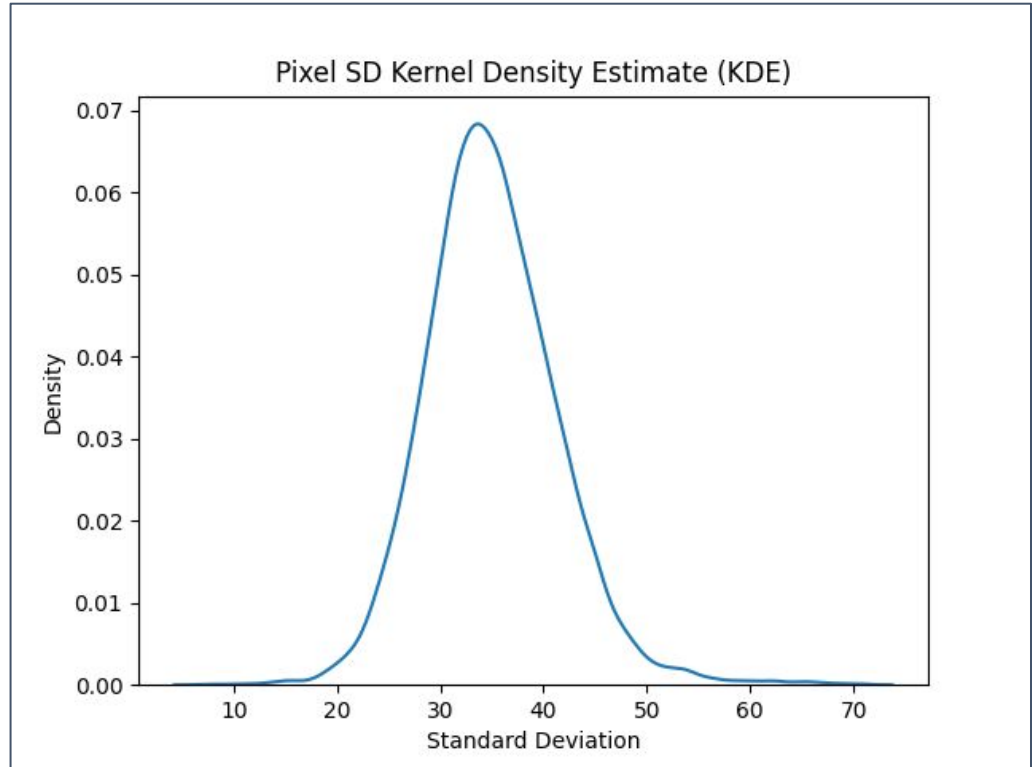
Base de Dados – EDA I

- Pouca utilidade para extrair *insights*;
- Imagens “claras” e “escuras”;
- Valores bem distribuídos.





Base de Dados – EDA I

- Distribuição Gaussiana;
- Presença de *outliers*;
- Contraste de imagens;
- Técnicas de PDI.



Base de Dados - EDA I




Disponível em:

https://www.researchgate.net/figure/Example-of-histogram-equalization-a-The-input-image-and-b-its-graylevel-histogram_fig1_269694707

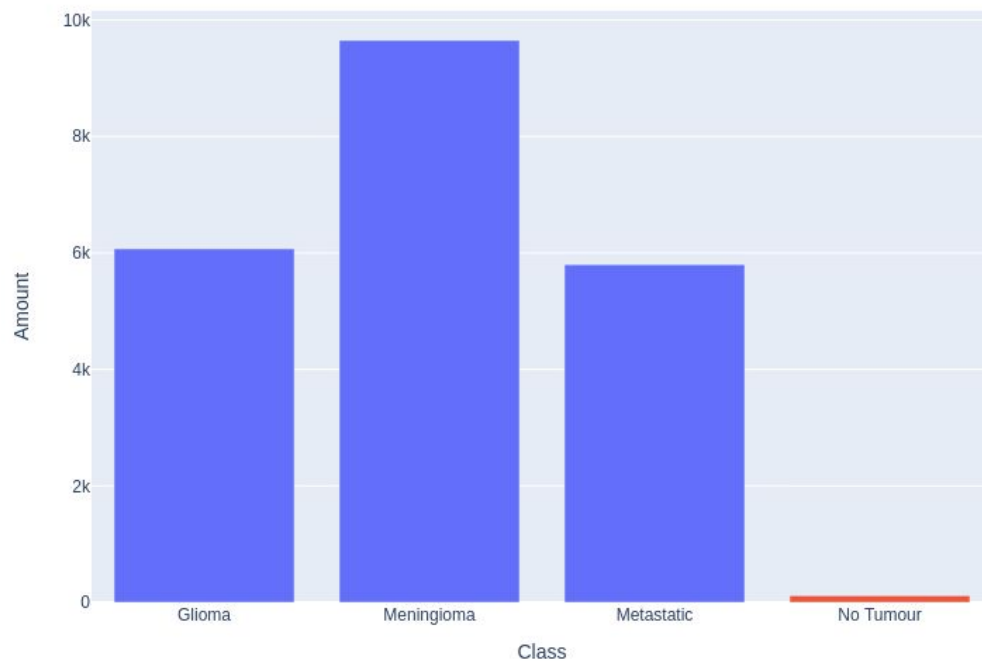
Base de Dados – EDA II

- Poucas imagens sem tumor;
- 2 ou mais tumores em média;
- Imagens não possuem mais de 1 tumor do mesmo tipo;
- Desbalanceamento para detecção.



Base de Dados – EDA II

Class Distribution



Modelo

kaggle™



- Kaggle: 8 algoritmos;
- Escolhido: Brain Tumor Detection w/Keras YOLO V8;
 - Algoritmo de Detecção;
 - Melhores métricas;
 - YOLO – You Only Look Once;
 - Versão 8;
 - Única CNN;
 - Previsão de classes e caixas delimitadoras;

Disponível em:

<https://zeeshanusmani.com/2019/10/16/how-to-host-effectively-on-kaggle/>

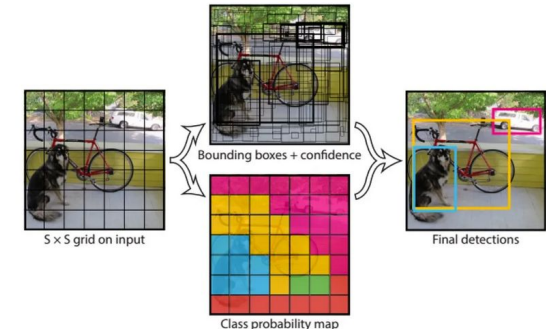

https://commons.wikimedia.org/wiki/File:Tensorflow_logo.svg

<https://pjreddie.com/darknet/yolo/>

Modelo – Visão Geral

1. A imagem de entrada é passada por uma CNN para extrair características da imagem;
2. As características são passadas através de uma série de camadas totalmente conectadas, que preveem a probabilidades de classe e as coordenadas da caixa delimitadora;
3. A imagem é dividida em uma grade de células e cada célula é responsável por prever um conjunto de caixas delimitadoras e probabilidades de classe;

4. As caixas delimitadoras são então filtradas usando um algoritmo de pós-processamento para remover caixas sobrepostas e escolher a caixa com a maior probabilidade;
5. A saída final é um conjunto de caixas delimitadoras previstas e rótulos de classe para cada objeto na imagem.



Disponível em:

<https://kili-technology.com/data-labeling/machine-learning/yolo-algorithm-real-time-object-detection-from-a-to-z>


<https://arxiv.org/abs/1506.02640>

Modelo – Metodologia

- Modelo YOLO v8
 - Pré-processamento: Escala das imagens, 640 x 640;
 - Backbone: pesos pré-treinados com o dataset COCO;
 - Otimizador: AdamW;
 - Função de custo da classificação: Binary Cross-Entropy;
 - Função de custo da detecção: CloU;
 - 120 épocas;

Algoritmo - Metodologia

- Ajuste dos pesos através das funções de custo:
 - Binary Cross-Entropy: Custo em relação a classificação do objeto
 - Medir a discrepância entre as probabilidades preditas e as probabilidades reais;
 - CloU: Custo em relação a detecção do objeto
 - Medir a sobreposição entre duas caixas delimitadoras;
 - IoU alta, boa sobreposição



Intersection over Union

$$IoU = \frac{B_1 \cap B_2}{B_1 \cup B_2} = \frac{\text{Intersection}}{\text{Union}}$$


The diagram shows the intersection of the two boxes (shaded blue) and the union of the two boxes (shaded blue).

Modelo – Métricas

- A cada iteração, o modelo calcula as seguintes medidas:
 - **Box Loss:**
 - Função de custo da detecção
 - Erro da sobreposição das caixas delimitadoras
 - **Class Loss:**
 - Função de custo da classificação
 - Erro da classificação dos dados
 - **Loss:**
 - Soma das perdas




Modelo - Métricas

- Métricas realizadas pelo modelo em relação ao conjunto de treinamento e o conjunto de validação:






Modelo - Resultados

- Padrão Ouro x Previsão






Modelo - Resultados

- Padrão Ouro x Previsão






Modelo - Resultados

- Padrão Ouro x Previsão






Modelo - Resultados

- Padrão Ouro x Previsão






Modelo - Resultados

- Padrão Ouro x Previsão



Modelo - Resultados

- Padrão Ouro x Previsão



Conclusões

- Dataset
 - Qualidade das imagens do dataset;
 - Desbalanceamento do dataset;
- Modelo
 - Tempo de execução do modelo;
 - Métricas não mensuradas para o conjunto de teste;
- Próximos passos:
 - Considerar técnicas de PDI;
 - Diminuir o tempo de treinamento;
 - Gerar métricas do conjunto de teste;
 - Avaliar fine-tuning;

Referências Bibliográficas

- *"Medical Image DataSet: Brain Tumor Detection."* Kaggle,
<https://www.kaggle.com/pkdarabi/medical-image-dataset-brain-tumor-detection?resource=download>.
Acessado em 14/04/2024.
- *"YOLO Algorithm: Real-Time Object Detection from A to Z."* Kili,
<https://kili-technology.com/data-labeling/machine-learning/yolo-algorithm-real-time-object-detection-from-a-to-z>.
Acessado em 20/04/2024.

Referências Bibliográficas

- "Detecção de Objetos com YOLO – Uma abordagem moderna." *IA Expert Academy*,
<https://iaexpert.academy/2020/10/13/deteccao-de-objetos-com-yolo-uma-abordagem-moderna>.
Acessado em 23/04/2024.
- "Performance Metrics Deep Dive." *Ultralytics YOLOv8 Docs*,
<https://docs.ultralytics.com/guides/yolo-performance-metrics/#how-to-calculate-metrics-for-yolov8-model>.
Acessado em 25/04/2024.